



数据仓库


学习目标

数据仓库介绍

1. 数据仓库概念

数据仓库概念创始人在《建立数据仓库》一书中对数据仓库的定义是：数据仓库（Data Warehouse）是一个**面向主题的**（Subject Oriented）、**数据集成的**（Integrated）、**相对稳定**（非易失的）（Non-Volatile）、反映历史变化（**时变**）（Time Variant）的数据集合，用于**支持管理决策**（Decision Making Support）。

数据仓库是决策支持系统（dss）的结构化数据环境，如下图，**决策支持系统基于数据仓库**进行联机分析处理（OLAP）。常用的技术有，HDFS、HBase、Hive、SparkSql等。



1. 数据采集，将源数据采集到数据仓库
2. 基于数据仓库进行数据分析



3. 生成报表

2. OLTP和OLAP区别

OLTP (On-Line Transaction Processing) 即联机事务处理，也称为面向交易的处理过程，其基本特征是前台接收的用户数据可以立即传送到计算中心进行处理，并在很短的时间内给出处理结果，是对用户操作快速响应的方式之一，比如ERP系统，CRM系统，互联网电商系统等，这类系统的特点是事务操作频繁，数据量小。

OLAP (On-Line Analytical Processing) 即联机分析处理，有时也称为决策支持系统 (DSS)，支持复杂的分析操作，侧重决策支持，并且提供直观易懂的查询结果。这类系统的特点是没有事务性操作，主要是查询操作，数据量大。

详细的区别如下：

对比项目	OLTP	OLAP
功能	面向交易的事务处理	面向分析查询
设计	面向业务	面向主题
数据	最新数据，二维数据	历史数据，多维数据
存储	M、G (存储单位)	T、P、E
响应时间	快	慢
用户	业务操作人员	管理决策人员





3. 数据仓库的特点

数据仓库系统流程

1. 系统流程图

数据仓库提供企业决策分析的数据环境，数据从哪里获取？数据如何存储到数据仓库？决策分析系统如何从数据仓库获取数据进行分析？我们可以把数据从获取、存储到数据仓库、数据分析的所有部分称为一个数据仓库系统，本节讲解数据仓库系统的工作流程和系统架构。

下图是数据仓库系统的结构图：



以下系统各部分的执行流程是：



- 1、确定分析所依赖的源数据。
- 2、通过ETL将源数据采集到数据仓库。
- 3、数据按照数据仓库提供的主题结构进行存储。
- 4、根据各部门的业务分析要求创建数据集市（数据仓库的子集）。
- 5、决策分析、报表等应用系统从数据仓库查询数据、分析数据。
- 6、用户通过应用系统查询分析结果、报表。

2. 源数据

源数据是指用于分析的原始数据，这一步主要是根据分析需求确定源数据，这个数据分布在内部系统和外部分系统中，内部数据主要是企业ERP系统、外部数据是指企业外部分系统所产生的数据，通常是指行业数据。源数据最大的特点是格式不统一，如果要对源数据进行分析需要经过ETL对数据进行集中获取、过虑、转换等处理。

3. ETL

ETL (Extra, Transfer, Load) 包括**数据抽取**、**数据转换**、**数据装载**三个过程。

1、抽取

数据抽取是从各各业务系统、外部系统等源数据处采集源数据。

2、转换

采集过来的源数据如果要存储到数据仓库需要按照一定的数据格式对源数据进行转换，常见的转换方式有数据类型转换、格式转换、缺失值补充、数据综合等。

3、装载

转换后的数据就可以存储到数据仓库中，这个过程要装载。数据装载通常是按一定的频率进行的，比如每天装载当天的订单数据、每星期装载客户信息等。

4. 数据仓库与数据集市

数据仓库是用于企业整体分析的数据集合，比如分为：销售主题、客户主题、产品主题等。数据集市是用于部门分析的数据集合，从范围上来讲它属于数据仓库的子集，比如：销售部门的数据集市只有销售主题。



为什么会有数据集市的概念？

通常从企业整体出发去建数据仓库比较困难，所涉及到的业务及分析需求比较多，所以提出数据集市的概念，可以先从某个部门开始建设数据仓库，这样效率就比较高。

业界把从企业整体出发建设数据仓库的过程叫自顶向下，把从数据集市开始建设数据仓库再逐渐完善整个数据仓库的过程叫自下向上。通常建议自下向上建设数据仓库，不过这个在业界也存在争议。

数据仓库和数据集市具有什么区别？

1、范围的区别

数据仓库是针对企业整体分析数据的集合。

数据集市是针对部门级别分析的数据集合。

2、数据粒度不同

数据仓库通常包括粒度较细的数据明细。

数据集市则会在数据仓库的基础上进行数据聚合，这些聚合后的数据就会直接用于部门业务分析。

5. 应用系统

这里的应用系统是指使用数据仓库完成数据分析、数据查询、数据报表等功能的系统。应用系统需要从数据仓库中查询数据、分析数据，比如：OLAP 系统、数据查询系统等。

6. 用户

使用数据仓库系统的用户主要有数据分析人员、管理决策人员（公司高层）等。





维度分析

1. 维度分析介绍

对数据进行分析通常采取维度分析，比如：用户提出分析课程访问量的指标，为了满足不同的分析需求可以从时间维度分析课程访问量，分析每天、每小时的课程访问量；也可以从课程维度来分析课程访问量，分析每个课程、每个课程分类的访问量。

2. 指标与维度

要进行维度分析需要先理解两个术语：指标和维度。

指标是衡量事务发展的标准，也叫度量，如销售额，销量等，多为行为事实数据；指标可以求和、求平均值等计算。

维度是事务的特征，如颜色、区域、时间等，可以根据不同的维度来对指标进行分析对比。比如根据区域维度来分析不同区域的产品销量，根据时间来分析每个月产品的销量，同一个产品销量指标从不同的维度分析会得出不同的结果。

用具体的指标数值，来度量不同的维度。x轴和y轴的关系。

3. 下钻与上卷

维度中有不同的层次，每个层次可以有多个级别，这样就可以根据多个维护层次和级别进行分析，可以灵活获取高级别的汇总信息，获取低级别的明细信息。

把获取高级别的汇总信息的过程叫上卷，把获取低级别的明细信息的过程叫下钻，比如：课程访问量分析，时间维度有四个级别，分别是年、月、天、小时，现在我们某个级别分析每天的课程访问量，比如按天分析课程访问量，此时我们可以按小时下钻分析，得出一天内每小时的课程访问量，也可以按月上卷，得到月度的课程访问量。

下钻维度：

天、小时

上卷维度：





年、月

数仓模型

1. 概述

数据仓库建模的方法常用的有两种：三范式建模法、维度建模法，三范式建模法主要是应用于传统的企业级数据仓库，这类数据仓库通常使用关系型数据库实现，是由Inmon提出的，应用于自顶向下的数据仓库架构；维度数据模型就是基于维度分析来创建模型，是由Kimball提出，应用于自下向上的数据仓库架构。本课程采用维度建模的方法。

维度建模，简称DM（Dimensional modeling），数据仓库大师Kimball的观点：维度数据模型是一种趋向于支持最终用户对数据仓库进行查询的设计技术，是围绕性能和易理解性构建的。维度模型是按照用户看待或分析数据的角度来组织数据。

维度建模的两个核心概念：事实表和维度表。

1.1 事实表

事实表记录了特定行为事件的数字化信息，一般由数值型数字和指向维度表的外键组成。此类数据的数据量较大，更新比较频繁。

事实表的设计依赖于业务系统，事实表的数据可以计算出业务系统的指标数据。数据分析的实质就是基于事实表开展的计算操作。

思考：

- 1、行为事实数据在线状图中在x轴还是y轴？
- 2、指标数据在sql统计中，处于什么位置？

1.2 维度表

1.2.1 概述

维度是指观察数据的角度，一般是一个名词，比如对于销售金额这个事实，我们可以从销售时



间、销售产品、销售店铺、购买顾客等多个维度来观察分析。

维度表的记录数比事实表少，但是每条记录可能会包含很多字段。

1.2.2 分类

主要包含两大类数据：

1. **高基数维度数据**：一般是用户资料表、商品资料表类似的资料表。数据量可能是千万级或者上亿级别。
2. **低基数维度数据**：一般是配置表，比如枚举值对应的中文含义，或者日期维表、地理维表等。数据量可能是个位数或者几千条几万条。

基数指的是一个字段中不同值的个数，比如**主键**列具有唯一值，所以具有最高的基数，而**性别**枚举值（日期、地区等）这样的列的基数就很低。

栗子：

时间维度表

描述事件发生的时间，数据仓库就是一个随时间变化的数据集合，因此可能需要一个时间维度表。年月日时分秒。

地理维度表

描述地理位置信息数据，国家、省市县镇村、邮编等。

产品维度表

描述产品属性。比如书的分类，有科技、教育、小说等分类属性。


人员维度表

描述人员相关信息，销售人员、市场人员、开发人员等。

1.2.3 思考

- 1、事实数据和维度数据在线状图中谁是x轴谁是y轴？





2、事实数据和维度数据在统计sql中，分别处于什么位置？

```
select count(order_id) order_num, sum(order_price) price
from t_order
group by year_month;
```

1.3 常见的建模方法


1.3.1 星型模型

是一种多维的数据关系。**一个事实表为中心，多个维度表环绕周围。**

一个星型模型中可以有一个或多个事实表，每个事实表可以引用任意数量的维度表。

星型模型将业务流程分为事实 and 维度。事实是对业务的度量，是定量的数据，比如价格、销售数量、距离、速度、质量等。维度是对事实数据属性的描述，比如日期、产品、客户、地理位置等。






1.3.2 雪花模型

当有一个或多个维表没有直接连接到事实表上，而是通过其他维表连接到事实表上时，就像多个雪花连接在一起，故称雪花模型。雪花模型是对星型模型的扩展，它对星型模型的维表进一步层次化，原有的各维表可能被扩展为小的事实表，形成一些局部的“层次”区域，这些被分解的表都连接到主维度表而不是事实表。





如何将维度表进行层次化处理呢？

即把低基数（重复比较多、辨识度比较低、维度数据少，比如性别）的属性从维度表中移除并形成单独的表。

比如之前讲到的案例，购买量指标有课程维度，课程维度又可以将课程分类进行层次化扩展为新的维度表。

层次化的影响

层次化的过程是将维度表中重复度比较高的字段组成一个新表，所以层次化不可避免增加了表的数量，减少了数据的存储空间，提高了数据更新的效率。但是查询时就需要连接更多的表。

总结，雪花模型中，一个维度被规范化成多个关联的表，星型模型中，每个维度由一个单一的维度表所表示。

2. 渐变维 (SCD)

2.1 什么是渐变维

维度可以根据变化剧烈程度主要分为无变化维度和变化维度。例如一个人的相关信息，身份证号、姓名和性别等信息数据属于不变的部分；而婚姻状态、工作经历、工作单位和培训经历等属于可能会变化的字段。

大多数维度数据随时间的迁移是缓慢变化的。比如增加了新的产品，或者产品的ID号码修改了，



或者产品增加了一个新的属性，此时，维度表就会被修改或者增加新的记录行。这样，在设计维度和使用维度的过程中，就要考虑到缓慢变化维度数据的处理。

缓慢渐变维，即维度中的属性可能会随着时间发生改变，比如包含用户住址Address的DimCustomer维度，用户的住址可能会发生改变，进而影响业务统计精度，DimCustomer维度就是缓慢渐变维（SCD）。

SCD有三种分类，我们这里以顾客表为例来进行说明：

假设在第一次从业务数据库中加载了一批数据到数据仓库中，当时业务数据库有这样的一条顾客的信息。

CustomerID	FullName	City	Occupation
1001	BIWORK	Beijing	BI Engineer

顾客 BIWORK，居住在北京，目前是一名 BI 的开发工程师。假设 BIWORK 因为北京空气质量 PM2.5 等原因从北京搬到了三亚。那么这条信息在业务数据库中应该被更新了。

CustomerID	FullName	City	Occupation
1001	BIWORK	Sanya	BI Engineer

那么当下次从业务数据库中抽取这类信息的时候，数据仓库又应该如何处理呢？

我们假设在数据仓库中实现了与业务数据库之间的同步，数据仓库中也直接将词条数据修改更新。后来我们创建报表做一些简单的数据统计分析，这时在数据仓库中所有对顾客 BIWORK 的销售都指向了 BIWORK 新的所在地 - 城市三亚，但是实际上 BIWORK 在之前所有的购买都发生在 BIWORK 居住在北京的时候。

通过这个简单的例子，描述了因一些基本信息的更改可能会引起数据归纳和分析出现的问题。

2.2 SCD1（缓慢渐变类型1）

通过更新维度记录直接覆盖已存在的值。不维护记录的历史。一般用于修改错误的信息，即历史数据就是错误数据，除此没有他用。

在数据仓库中，我们可以保持业务数据和数据仓库中的数据始终处于一致。可以在 Customer 维度中使用来自业务数据库中的 Business Key - CustomerID 来追踪业务数据的变化，一旦发生变化那么就将旧的业务数据覆盖重写。

DW 中的记录根据业务数据库中的 CustomerID 获取了最新的 City 信息，直接更新到 DW 中。

CustomerID	FullName	City	Occupation
1001	BIWORK	Sanya	BI Engineer



2.3 SCD2 (缓慢渐变类型2)

在源数据发生变化时，给维度记录建立一个新的“版本”记录，从而维护维度历史。SCD2不删除、不修改已存在的数据。SCD2也叫拉链表。

在数据仓库中有很多需求场景会对历史数据进行汇总和分析，因此会尽可能的维护来自业务系统中的历史数据，使系统能够真正捕获到这种历史数据的变化。

以上面的例子来说，可能需要分析的结果是 BIWORK 在 2012年的时候购买额度整体平稳，但是从2013年开始购买额度减少了。出现的原因可能与所在的城市有关系，在北京的门店可能比在三亚的门店相对要多一些。

像这种情况，就不能很简单在数据仓库中将 BIWORK 当前所在城市直接更新，否则此用户所有的购买额度都会归于三亚。

通过起始时间来标识，Valid To (封链时间) 为 NULL 的标识当前数据，也可以用2999, 3000, 9999等等比较大的年份。数仓内部需要保持统一。每个版本都会产生一行新的数据。

DWID	CustomerID	FullName	City	Occupation	Valid From	Valid To
1	1001	BIWORK	Beijing	BI Engineer	2012-01-01 00:00:00	2012-03-12 12:33:22
2	1001	BIWORK	Sanya	BI Engineer	2012-03-12 12:33:22	NULL

2.4 SCD3 (缓慢渐变类型3)

实际上SCD1 and 2 可以满足大多数需求了，但是仍然有其它的解决方案，比如说 SCD3。SCD3希望只维护更少的历史记录。

比如说把要维护的历史字段新增一列，然后每次只更新 Current Column 和 Previous Column。这样，只保存了最近两次的历史记录，历史数据都在同一行数据中。但是如果维护的字段比较多，就比较麻烦，因为要更多的 Current 和 Previous 字段。所以 SCD3 用的还是没有SCD1 和 SCD2 那么普遍。它只适用于数据的存储空间不足并且用户接受有限历史数据的情况。


CustomerID	FullName	Current City	Previous City	Occupation
1001	BIWORK	Sanya	Beijing	BI Engineer



3. 数据仓库分层


3.1 为什么要分层？

作为一名数据的规划者，我们肯定希望自己的数据能够有秩序地流转，数据的整个生命周期能够清晰明确被设计者和使用者感知到。直观来讲就是如图这般层次清晰、依赖关系直观。



但是，大多数情况下，我们完成的数据体系却是依赖复杂、层级混乱的。如下的右图，在不知不觉的情况下，我们可能会做出一套表依赖结构混乱，甚至出现循环依赖的数据体系。





因此，我们需要一套行之有效的数据组织和管理方法来让我们的数据体系更有序，这就是谈到的数据分层。数据分层并不能解决所有的数据问题，但是，数据分层却可以给我们带来如下的好处：

1. 清晰数据结构：每一个数据分层都有它的作用域和职责，在使用表的时候能更方便地定位和理解。
2. 复杂问题简单化：将一个复杂的任务分解成多个步骤来完成，每一层解决特定的问题。
3. 便于维护：当数据出现问题之后，可以不用修复所有的数据，只需要从有问题的步骤开始修复。
4. 减少重复开发：规范数据分层，开发一些通用的中间层数据，能够减少重复开发的工作量。
5. 高性能：数据仓库的构建将大大缩短获取信息的时间，数据仓库作为数据的集合，所有的信息都可以从数据仓库直接获取，尤其对于海量数据的关联查询和复杂查询，所以数据仓库分层有利于实现复杂的统计需求，提高数据统计的效率。

3.2 常规分层方法

尽管不同的公司和业务线的层级有的是四层，有的是五层，但究其本质都是三层结构，即原始层(ODS)、中间层(DW)和应用层(APP/DA/ADS)。



3.2.1 源数据层 (ODS)

此层数据无任何更改，直接沿用外围系统数据结构和数据，不对外开放；为临时存储层，是接口数据的临时存储区域，为后一步的数据处理做准备。

3.2.2 数据仓库层 (DW)

DW 层的数据应该是一致的、准确的、干净的数据，即对源系统数据进行了清洗（去除了杂质）后的数据。

此层可以细分为三层：

1. 明细层DWD (Data Warehouse Detail)：存储明细数据，此数据是最细粒度的事实数据。该层一般保持和ODS层一样的数据粒度，并且提供一定的数据质量保证。同时，为了提高数据明细层的易用性，该层会采用一些维度退化手法，将维度退化至事实表中，减少事实表和维表的关联。
2. 中间层DWM (Data WareHouse Middle)：存储中间数据，为数据统计需要创建的中间表数据，此数据一般是对多个维度的聚合数据，此层数据通常来源于DWD层的数据。
3. 业务层DWS (Data WareHouse Service)：存储宽表数据，此层数据是针对某个业务领域的聚合数据，应用层的数据通常来源与此层，为什么叫宽表，主要是为了应用层的需要在这一层将业务相关的所有数据统一汇集起来进行存储，方便业务层获取。此层数据通常来源与DWD和DWM层的数据。

在实际计算中，如果直接从DWD或者ODS计算出宽表的统计指标，会存在计算量太大并且维度太少的问题，因此一般的做法是，在DWM层先计算出多个小的中间表，然后再拼接成一张DWS的宽表。由于宽和窄的界限不易界定，也可以去掉DWM这一层，只留DWS层，将所有数据放在DWS亦可。

3.2.3 数据应用层 (DA 或 APP)

前端应用直接读取的数据源；根据报表、专题分析的需求而计算生成的数据。


3.2.4 维表层 (Dimension)

最后补充一个维表层，维表层主要包含两部分数据：

1. 高基数维度数据：一般是用户资料表、商品资料表类似的资料表。数据量可能是千万级或者上亿级别。
2. 低基数维度数据：一般是配置表，比如枚举值对应的中文含义，或者日期维表。数据量可能



是个位数或者几千几万。



3.2.5 数据仓库设计案例

这里我们以电商网站的数据仓库为例，针对用户访问日志这一部分数据进行举例说明。

在ODS层中，由于各端的开发团队不同或者各种其它问题，用户的访问日志被分成了好几张表上报到了我们的ODS层。


为了方便大家的使用，我们在DWD层做了一张用户访问行为天表，在这里，我们将PC网页、H5、小程序和原生APP访问日志汇聚到一张表里面，统一字段名，提升数据质量，这样就有了一张可供大家方便使用的明细表了。

在DWM层，我们会从DWD层中选取业务关注的核心维度来做聚合操作，比如只保留人、商品、设备和页面区域维度。类似的，我们这样做了很多个DWM的中间表。

然后在DWS层，我们将一个人在整个网站中的行为数据放到一张表中，这就是我们的宽表了，有了这张表，可以快速满足大部分的通用型业务需求了。

最后，在APP应用层，根据需求从DWS层的一张或者多张表取出数据拼接成一张应用表即可。





4. 阿里巴巴数仓分层

在阿里巴巴的数据体系中，建议将数据仓库分为三层，自下而上为：数据引入层（ODS，Operation Data Store）、数据公共层（CDM，Common Data Model）和数据应用层（ADS，Application Data Service）。





数据应用层（ADS）

个性化指标加工：定制化、复杂性指标（大部分复合指标）
基于应用的数据组装：宽表集市、趋势指标

数据公共层（CDM）

维度表（DIM）：建立一致数据分析维表、降低数据计算口径和算法不统一风险
公共汇总层（DWS）：构建命名规范、口径一致的统计指标，为上层提供公共指标，建立汇总宽表
明细事实表（DWD）：基于维表建模，明细宽表，复用关联计算，减少数据扫描

数据引入层（ODS）

同步：结构化数据增量或全量同步到MaxCompute
结构化：非结构化数据（日志）进行结构化处理，并存储到MaxCompute
保存历史、清洗：根据业务、审计、稽查的需求保留历史数据或进行清洗

4.1 数据引入层ODS（Operation Data Store）

存放未经处理的原始数据至数据仓库系统，结构上与源系统保持一致，是数据仓库的数据准备区。主要完成基础数据引入到MaxCompute(阿里云大数据计算服务，原名ODPS)的职责，同时记录基础数据的历史变化。

4.2 数据公共层CDM（Common Data Model）

又称通用数据模型层。包括DIM维度表、DWD和DWS，由ODS层数据加工而成。主要完成数据加工与整合，建立一致性的维度，构建可复用的面向分析和统计的明细事实表，以及汇总公共粒度的指标。

4.2.1 公共维度层（DIM）

基于维度建模理念思想，建立整个企业的一致性维度。降低数据计算口径和算法不统一风险。

公共维度层的表通常也被称为逻辑维度表，维度和维度逻辑表通常一一对应。

4.2.2 公共汇总粒度事实层（DWS）

以分析的主题对象作为建模驱动，基于上层的应用和产品的指标需求，构建公共粒度的汇总指



标事实表，以宽表化手段物理化模型。构建命名规范、口径一致的统计指标，为上层提供公共指标，建立汇总宽表、明细事实表。

公共汇总粒度事实层的表通常也被称为汇总逻辑表，用于存放派生指标数据。

4.2.3 明细粒度事实层 (DWD)

以业务过程作为建模驱动，基于每个具体的业务过程特点，构建最细粒度的明细层事实表。可以结合企业的数据使用特点，将明细事实表的某些重要维度属性字段做适当冗余，即宽表化处理。


明细粒度事实层的表通常也被称为逻辑事实表。

4.3 数据应用层ADS (Application Data Service)

存放数据产品个性化的统计指标数据。根据CDM与ODS层加工生成。

4.4 总结

该数据分类架构在ODS层分为三部分：数据准备区、离线数据和准实时数据区。整体数据分类架构如下图所示。




从交易数据系统的数据经过数据集成，同步到数据仓库的ODS层。经过数据开发形成事实宽表




后，再以商品、地域等为维度进行公共汇总。

数据流向图



5. 美团数仓分层

数据仓库建模规范



5.1 ODS（数据源）

数据源层，主要职责是接入数据源，并做多数据源的整合。从数据源落地到 Hive 表，同时与数据来源保持一致，尽量还原业务。主要由四类数据源：业务库数据、流量日志、集团数据、三方



数据。

5.2 IDL (集成明细层)

数据集成层，主要是明细数据，与上一层数据源层是有对应关系的。主要职责是：业务主题的划分、数据规范化，比如商家、交易、用户等多个主题。这一层主要起到缓冲的作用，屏蔽底层影响，尽量还原业务，统一数据标准，敏感字段脱敏，字段名称标准化、Json字段拉平等。

5.3 CDL (中间组件层)

数据组件层，主要职责是建设基础指标的多维明细模型、轻度汇总模型。比如商家交易、用户活动等多个主题的基础指标模型。这样针对同一个分析对象统一了指标口径，同时避免重复计算。

数据组件层生成的指标主要是原子指标，原子指标形成数据组件，方便下游的集市层以及应用层拼接数据表。

数据仓库建模规范 – 数据组件层

美团 美团点评



5.3.1 多维明细模型

以商家信息表建设过程为例：

识别分析对象：首先明确分析对象为商家实体，

圈定分析边界：多维明细不需要关联实体行为，只需要识别出实体之后圈定商家属性信息作为分析边界；



丰富对象属性：提取商家属性信息，比如商家的品类信息、组织结构信息等

以上信息就形成了一个由商家主键和商家多维信息组成的商家实体的多维明细模型。

5.3.2 轻度汇总模型

以商家交易表假设过程为例：

识别分析对象：分析实体是商家，业务行为是交易，分析对象是商家交易

圈定分析边界：圈定提交表、商家信息表、订单状态表、会员表作为商家交易的边界

丰富对象属性：将城市、组织结构等维度信息冗余进来，丰富维度属性信息

汇总商家粒度、交易额等原子指标最终建立商家交易表。

5.4 MDL (集市层)

数据集市层，主要职责是建设宽表模型、汇总表模型，比如商家宽表、商家时段汇总表等。主要作用是支撑数据分析查询以及支持应用所需数据。

宽表模型和汇总模型两者的区别是：宽表模型是唯一主键，基于主键拼接各种信息；汇总模型的主键类型为联合主键，根据公共维度关联生成派生指标，丰富信息。

5.4.1 宽表模型

订单宽表为例，建设过程为：选定订单实体作为实体对象，然后圈定订单明细、订单状态、订单活动、订单收购等分析对象通过订单 id 进行关联。这里的宽表模型与数据组件层的多维明细模型的区别在于多维明细模型里的实体对象粒度更细，例如订单宽表中分析对象：订单明细、订单状态、订单活动等都是多维明细模型里的一个个数据组件，这几个数据组件通过订单 id 关联拼接形成了宽表模型。

5.4.2 汇总模型

商家时段汇总表为例，建设过程为：选定商家、时段维度作为维度组合，圈定商家和时段维度相关的表，通过公共维度进行关联、维度冗余，支持派生指标、计算指标的建设。这里区别于组件层的轻度汇总模型，在数据组件层建设的是原子指标，而数据集市层建设的是派生指标。

5.5 ADL (应用层)

数据应用层，主要职责是建设应用分析、支撑多维分析应用，比如城市经营分析等。



应用层一般的操作有：数据裁剪、上卷聚合、模型拼接、指标计算（不可加事实指标，如比率）等。

应用层的查询引擎要根据应用场景来选择，比如：Mysql、Presto、Hbase、Redis、ES、Kylin、Doris等。

其中 ODS/IDL/CDL，以及部分 MDL 集市由数据基建组来做，另外部分数据集市以及 ADL 应用层由数据应用组支撑，分工标准是涉及一些公共的数据集市由数据基建组来完成；数据应用组会围绕应用建设应用数据集市，如流量集市、城市经营集市。

6. 亿品新零售数仓分层



6.1 ODS数据源

同标准分层中的ODS，略。





6.2 DWD明细层

同标准分层中的DWD，略。

6.3 DWB基础数据层

数据降维后生成的明细宽表，作为中间数据使用。

与标准分层中的DWM层宽表功能类似。

6.4 DWS服务数据层

按照主题划分的日统计宽表，基于DWB上的基础数据，整合汇总成分析某一个主题域的服务数据。

与标准分层中的DWM层轻度汇总功能类似。

6.5 DM数据集市

数据集市层，主要职责是建设宽表模型、汇总表模型，比如用户主题宽表、销售主题宽表等。主要作用是支撑数据分析查询以及支持应用所需数据。

与标准分层中的DWS数据集市类似。

6.6 RPT报表应用

同标准分层中的APP层、ADS层。

根据报表、专题分析的需求而计算生成的个性化数据。

